



基于 SqueezeNet 卷积神经网络的岩石薄片图像分类研究

程国建¹, 李 碧¹, 万晓龙², 姚卫华², 魏新善²

1. 西安石油大学计算机学院, 陕西 西安 710065;

2. 中国石油长庆油田分公司勘探开发研究院, 陕西 西安 710018

中图分类号: TP183; P588 文献标志码: A

文章编号: 1001-6872(2021)04-0094-08

收稿日期: 2021-05-20; 改回日期: 2021-07-16

基金项目: 国家自然科学基金“基于遥感大数据的汾渭平原空气质量时空特征及其驱动力研究与模拟”(62002286); 国家自然科学基金青年科学基金“基于多核学习的高分辨率光学遥感图像固定结构人造目标检测方法研究”(41301480)

第一作者简介: 程国建, 男, 57岁, 教授, 硕士生导师, 人工智能及应用专业, 研究方向: 人工智能、机器学习、模式识别、岩石薄片、图像分析等。

【摘 要】 在地质研究中, 针对岩石薄片图像分类算法可移植性不高、分类速度较慢等问题, 提出将轻量级卷积神经网络结构 SqueezeNet 应用于岩石薄片图像分类。实验的数据集为鄂尔多斯某油田区域的 10026 张长石砂岩图像, 图像大小均为 224×224 像素, 通过 SqueezeNet 网络模型进行训练, 在较短时间内实现了岩石薄片图像的分类, 并取得了较好分类效果, 验证集分类准确率最高可达到 90.88%。实验结果表明, 所提模型在保证准确率的同时, 大大减少了模型参数, 模型大小仅为 4.78 MB, 提升了岩石分类速度、增强了模型的可移植性。

【关键词】 岩石薄片图像; 卷积神经网络; SqueezeNet 卷积网络

0 引 言

岩石薄片图像是油气勘探与开发领域的专业研究者为了便于观察岩石的微观结构而制作的图像。通过对岩石薄片图像进行分析, 从而实现对其进行分类。然而仅仅依靠肉眼观察对岩石进行鉴定、识别, 对专业要求较高, 初学者和非专业人士很难从岩石薄片图像中快速获取有用的信息。

前期, 学者们使用机器学习方法对岩石图像进行分类: Singh 等^[1]使用玄武岩岩石薄片图像数据, 利用多层感知器神经网络进行分类; Mlynarczuk 等^[2]使用最近邻算法、k 近邻算法等方法实现岩石图像分类; 郭超等^[3]提出一种使用神经网络建立特征空间与岩石图像类别之间的映射关系的方法; 程国建等^[4]应用支持向量机实现分类。但机器学习分类方式存在很多不足, 例如分类过程较为繁琐, 分类准确度仍有待提高^[5]。

引用格式: 程国建, 李 碧, 万晓龙, 等. 基于 SqueezeNet 卷积神经网络的岩石薄片图像分类研究[J]. 矿物岩石, 2021, 41(4): 94-101.
Cheng Guojian, Li Bi, Wan Xiaolong, et al. Research on Classification of Rock Section Image Based on Squeezenet Convolutional Neural Network[J]. *Mineralogy and Petrology*, 2021, 41(4): 94-101.
doi: 10.19719/j.cnki.1001-6872.2021.04.09 中国知网(<https://www.cnki.net>)

近年来,国内外学者在计算机视觉领域深入研究,逐渐采用深度学习方法对岩石图像进行分类:如:程国建等^[6]等将聚类分割和神经网络相结合,对目标孔隙的平均识别准确率可达 95.12%;程国建等^[7]等提出了一种基于卷积神经网络的岩石粒度自动分类方法,分类结果的准确度达到 98.5%;张野等^[8]在 Inception-v3 深度卷积神经网络模型的基础上进行分类,取得了良好的分类效果;程国建等^[9]提出一种基于深度信念网络的分类方法,准确性达到了 94.75%;程国建等^[10]提出利用单图像生成式对抗网络,不需输入大量数据集,对岩石薄片图像进行超分辨率重建。虽然采用深度学习对岩石图像分类已经比传统方法取得了较大进展和突破,但是在实际应用中面临着一定的弊端和局限性,例如:神经网络参数量大,自身结构复杂,训练得到的模型处理每张图片的速度较慢,且模型的可移植性不强。

SqueezeNet 是 2016 年被提出的精简卷积神经网络,李坤伦等^[11]等将轻量级卷积神经网络 SqueezeNet 用于实现对车辆颜色的识别,模型最终的分类结果为 96.48%;霍爱清等^[12]等提出结合深度残差网络和 GRU 网络的改进 SqueezeNet 模型,在 CIFAR-10 和 GTSRB 数据集上识别准确率分别达到 99.13% 和 88.25% 以上;鲁元平等^[13]使用 Squeezenet 模型对 10 种蛇类进行分类识别,识别率达到了 85.71%。

本次研究使用来自鄂尔多斯某油田区域的岩石 10026 幅薄片图像,将轻量级网络 SqueezeNet 应用于砂岩粒度分析,该卷积神经网络能够在实现尽量保证精度的情况下,将网络参数量比 AlexNet 减少近 50 倍^[14],甚至通过进一步处理,模型可以被压缩至仅 4.78 M,可以提高模型的处理速度、增强模型可移植性,使服务器同一时间可以处理更多的数据,提升硬件设备的使用效率。

1 岩石薄片图像

岩石薄片图像能够反映出岩石的微观特

征,因此,制作岩石薄片是观察岩石微观结构的有效途径。岩石薄片图像不仅直观的展示了孔隙的大小、孔喉、碎屑、颗粒的大小及排列形式,还能够反映出孔隙类型、空隙连通性、泥质含量、渗透率等参数特征^[15]。因此,岩石薄片图像对岩石微观结构的分析与研究发挥着至关重要的作用。本次研究的岩石薄片图像数据集以岩石颗粒度大小为依据可分为 5 类。具体特征为:

(1)第一类岩石:细粒长石砂岩,岩石颗粒细、大小相对均一,磨圆呈次棱角状。

(2)第二类岩石:细一中粒长石砂岩,岩石颗粒较细、大小相对混杂,杂基以泥质杂基为主,填充于颗粒之间。

(3)第三类岩石:中粒长石砂岩,岩石颗粒粗细中等、大小相对均一,杂基以泥质杂基为主,呈网状填充孔隙。

(4)第四类岩石:中一粗粒长石砂岩,岩石颗粒较粗、大小分布不等,颗粒支撑,孔隙一接触式胶结。以黏土杂基为主,呈雾状、网状填充孔隙。

(5)第五类岩石:粗粒长石砂岩,岩石颗粒粗,黏土矿物呈网状、薄膜状,颗粒边缘可见黏土薄膜出现,孔隙较为发育^[16]。

2 卷积神经网络及其架构

一个典型的卷积神经网络的结构中有输入层、卷积层、池化层、全连接层以及输出层,可以有若干个卷积层和池化层^[17]。

2.1 卷积层

卷积层(Convolutional layer)的作用主要是使用卷积核对输入的数据进行特征提取,再用卷积核与输入图像进行乘积,再加上偏置函数,通过激活函数激活,得出卷积之后每个神经元的输出结果。

2.2 激活函数

激活函数(Activation Function)是用来表示多层网络中上层节点输出和下层节点的输入之间具有的函数关系。

Softmax 函数将多个神经元的输出映射到 $(0,1)$ 区间内,并且所有映射得到的值总和为 1。设 V_i 表示数组 V 中的第 i 个元素,那么这个元素的 Softmax 值 S_i 的计算公式为^[18]:

$$S_i = \frac{e^{V_i}}{\sum_j e^{V_j}} \quad (1)$$

ReLU 函数是一种分段线性函数,所有输入负值的函数值都为 0,而正值的函数值为本身,从而实现单侧抑制。设 y 为输入 ReLU 函数中的自变量, $f(y)$ 为函数值,则计算公式为:

$$f(y) = \begin{cases} y & \text{if } y > 0 \\ 0 & \text{if } y \leq 0 \end{cases} \quad (2)$$

还有其他激活函数,例如 Sigmoid、Tanh、ELU 等有待进一步研究。

2.3 池化层

池化层(Pooling layer)包括最大池化层和平均池化层,它在保留原图特征的基础上,减小图片尺寸,降低计算量,加快卷积神经网络的训练速度,主要分为最大池化和平均池化两种类型。

2.4 全连接层

全连接层(Fully connected layers,)在卷积神经网络中可以起到“分类器”的作用。它将卷积层和池化层得到的局部特征重新通过权值矩阵进行整合为一个值,最终得到一个一维列向量。

3 深度卷积神经网络的几个变种

3.1 LeNet

1998 年,首次将 LeNet 卷积神经网络应用到图像分类上。LeNet 通过连续使用卷积和池化层的组合提取图像特征^[19]。由两个卷积层,两个池化层,两个全连接层组成,卷积核大小都是 5×5 ,步长为 1。

3.2 AlexNet

AlexNet 开创了使用深度神经网络解决图像问题的途径。AlexNet 对网络结构进行了加深,模型包含五个卷积层、三个全连接层,最后一层使用 Softmax 函数做分类输出。AlexNet

使用了 ReLU 作为激活函数,使用 dropout 层,从而避免过拟合现象^[20]。

3.3 GoogLeNet

GoogLeNet 引入了 Inception 模块,通过该模块可以融合不同尺度的特征信息,使分类效果更好。在其中通过 1×1 的卷积核进行降维,减少参数,减小运算量。由于网络太深,可能会出现训练梯度消失的现象,所以在网络中额外增加两个辅助分类器,用来帮助训练。

Inception-v3 网络是由 Google 开发的一个非常深的卷积网络。Inception-v3 网络的重要改进是引入了卷积拆分的思想,这种卷积结构拆分在减少计算量的同时,可以对空间特征进行更好的处理。

3.4 ResNet

ResNet 又名残差神经网络,指的是在传统卷积神经网络中加入残差单元,使网络在加深的同时,保证了精度。残差单元的结构特点是浅层输出一方面通过“主分支”,也就是一系列卷积层,得到深层输出,另一方面,浅层输出通过一个“捷径”,略过下一层而直达下下层与深层输出相加。若干个这样的残差模块堆叠,使分类时学习的特征更加丰富,提高了分类精度。

4 SqueezeNet 深度网络架构及其算法

SqueezeNet 卷积神经网络是由 UC Berkely 等在 2016 年提出的一个精简化的轻量级卷积神经网络结构,该模型在 AlexNet 网络的基础上做了改变,模型结构如图 1 所示:

SqueezeNet 网络结构最开始是一个卷积层,接下来由 8 个 Fire modules 组成,以一个卷积层结束,使用激活函数 Softmax 分类输出。在 Fire module 中,每一层的卷积核数量逐渐增加,Fire modules 包含 Squeeze 层和 Expand 层,每个 Squeeze 层和 Expand 层的输出时的激活函数都是 ReLU 函数,Fire9 模块后面用到了值为 50% 的 Dropout 层^[21]。

Squeeze 层中卷积核大小全部为 1×1 ,个

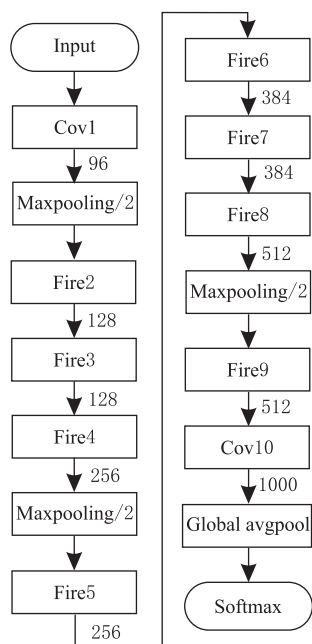


图1 SqueezeNet 模型结构

Fig.1 SqueezeNet model structure

数用 $s_1 \times x_1$ 表示, Expand 层包含两种卷积核, 分别是 1×1 、 3×3 , $e_1 \times x_1$ 表示 1×1 卷积核的个数, $e_3 \times x_3$ 表示 3×3 卷积核的个数。在 Fire Module 中, $s_1 \times x_1$ 要小于 $e_1 \times x_1$ 与 $e_3 \times x_3$ 的和。Fire Module 的结构如图 2 所示:




图2 Fire Module 结构

Fig.2 Fire Module structure

该网络的设计策略主要有:

(1) 将卷积网络中部分 3×3 的卷积核替换成 1×1 的卷积核, 这个操作可以将网络参数量降低 9 倍。

(2) 在不考虑偏置的情况下, 使用公式 $P = N \times C \times (3 \times 3)$ (N 为卷积核数量, C 为输入通

道数) 来表示 Expand 卷积层中的参数量, 所以, 除了降低 3×3 卷积核的数量以外, 还减少了 Expand 层中 3×3 卷积核的输入通道数, 从而可以降低整个网络的参数量。Fire Module 网络结构特征见图 3。

(3) 将池化操作延后, 这样可以保留更大的特征图, 从而传递更多的信息, 达到更高的分类精度^[22]。

5 岩石薄片图像分析

5.1 数据集

本次研究实验使用的数据集为鄂尔多斯某油田区域的岩石薄片图像。实验中共选取了 10026 幅大小为 224×224 像素的岩石图像, 其中训练集为细粒长石砂岩 1598 幅、细一中粒长石砂岩 1632 幅、中粒长石砂岩 1617 幅、中一粗粒长石砂岩 1619 幅、粗粒长石砂岩 1564 幅; 验证集为细粒长石砂岩 396 幅、细一中粒长石砂岩 406 幅、中粒长石砂岩 402 幅、中一粗粒长石砂岩 402 幅、粗粒长石砂岩 390 幅。

5.2 实验环境

实验在一台处理器为 InterCore i5-9400F、显卡型号为 Nvidia GeForce GTX1660、内存为 16GB 的计算机上进行, 软件配置采用 Python3.7 结合 PyTorch1.7, 对应 CUDA 版本为 11.0。

5.3 实验过程

(1) 模型构建

本次研究基于 PyTorch 深度学习平台建立分类模型。训练数据和测试数据在模型中分别迭代 300 次, 训练模型时采用了随机梯度下降优化算法 (Stochastic Gradient Descent, SGD)。使用 ReLU 函数, 实现非线性映射。为防止过拟合, 采用随机失活 (dropout) 技术, 其要删除神经元的比例设置为 0.5, 初始学习率设置为 0.001, 动量 (momentum) 是指训练损失函数值下降的趋势, 设置为 0.9。使用 Softmax 分类器, 将神经元的输出值映射到 (0, 1) 区间, 输出值经过映射后得到的结果为分类概

率,概率最大值即为预测值。

(2)算法描述

本次实验首先导入处理好的岩石图像数据集,接着进行构建网络,使用卷积层提取图像特征,接着通过最大池化层进行下采样操作,使用 Fire module 进一步实现降维,大大减少网络要学习的参数数量,采用 contact 方法进行特征融合。最后添加平均池化层整合全局空间信息,使用 Softmax 分类器输出分类。算法流程如图 3 所示:

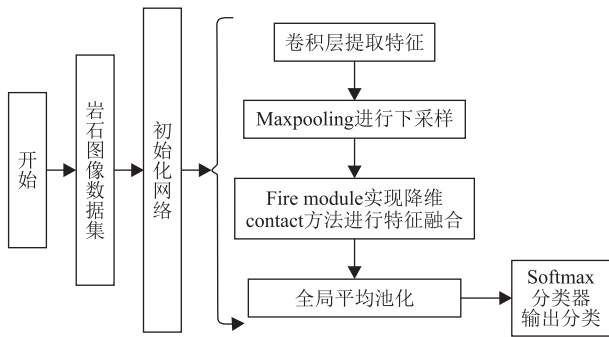


图 3 算法流程图
Fig. 3 Algorithm flow chart

(3)实验结果

图 4,图 5 为实验中训练集和验证集的损失函数曲线,图 6、图 7 为准确率曲线。由图可知,在第 200 次左右迭代时,曲线达到较为稳定的状态。训练集分类准确率最高可达到 92.5%,验证集分类准确率最高可达到 90.88%。




图 4 训练集上损失函数
Fig. 4 Loss function on the training set

5.4 模型对比结果

本次对比实验是在 SqueezeNet 模型和

AlexNet、GoogLeNet、Inception-v3、ResNet50 之间进行,除 SqueezeNet 外,其他网络在验证集上的准确率如表 1 所示:

表 1 各类深度网络模型验证集准确率对照表
Table 1 Accuracy comparison of various deep network model validation sets

模型	准确率/%
AlexNet	82.69
GoogLeNet	88.75
Inception-v3	86.18
ResNet50	90.24
SqueezeNet	90.88




图 5 验证集上损失函数
Fig. 5 Loss function on the validation set




图 6 训练集上准确率
Fig. 6 Accuracy on the training set

上表显示,SqueezeNet 模型在对参数量及模型大小有所改进的基础上,验证集的准确率与 AlexNet, GoogLeNet, Inception-v3, ResNet50 几个网络模型相比较,是最高的,达到了 90.88%,可以高效完成分类任务。

AlexNet, GoogLeNet, Inception-v3, ResNet50 四个模型相关准确率曲线见图 8,图 9:




图 7 验证集上准确率

Fig. 7 Accuracy on the validation set




图 8 训练集上准确率

Fig. 8 Accuracy on the training set

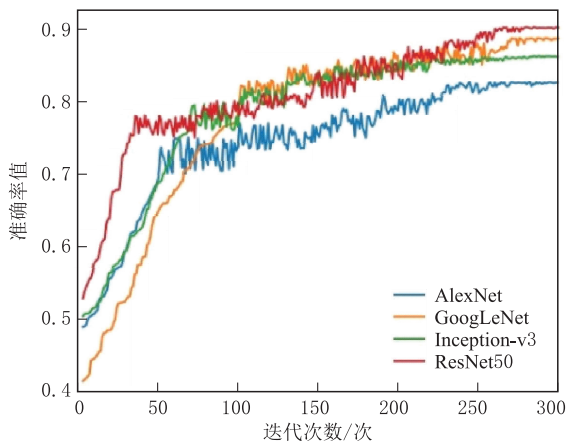


图 9 验证集上准确率

Fig. 9 Accuracy on the validation set

由以上图表,可以直观地看出在迭代次数相同的情况下几个模型的性能,在第 200 次迭代时,几个模型的准确率基本都趋于稳定。在验证集上 ResNet50 模型的性能已经非常突出,在之前几种模型的基础上已有较大提

升,可达 90.24%,而 SqueezeNet 模型的准确率也毫不逊色,最高可达 90.88%,可以高效完成分类任务。

从模型参数量的角度来看,SqueezeNet 网络的参数量大大少于其他深度神经网络,它具有很高的压缩率。各类深度网络模型参数量及模型大小对照见表 2。

表 2 各类深度网络模型参数量及模型大小对照表

Table 2 Comparison of various types of deep network model parameters and model sizes

模型	模型参数/ 10^6	模型大小/M
SqueezeNet	1.2	4.78
AlexNet	60.0	240.00
GoogLeNet	6.8	654.00
Inception-v3	24.7	96.00
ResNet50	25.5	97.80

由此表可得出,相比于其他网络,SqueezeNet 网络在保持性能相当的基础上,较大程度上减少了参数量。在计算机技术的应用中,SqueezeNet 网络这一特点可以在移动端设备的算法嵌入和功能应用上给人们以启发。

6 结 论

经过本次实验以及一系列研究,可得出以下结论:

(1) 本次研究实验结果表明,通过对 SqueezeNet 网络模型的不断调整,最终训练集分类准确率最高可达到 92.5%,验证集分类准确率最高可达到 90.88%。由于岩石图像的复杂性,在此领域的研究还有一定的进步空间,在今后的研究中,可以进一步调整网络结构、参数等以期获得更好的分类效果。

(2) 由于 SqueezeNet 规模小的特点,将来可以在内存小的可移动设备 FPGA 上实验,实现可移动式的岩石分类系统。

(3) 另外,由于实际岩石类型特征比较复杂,并且相关数据集非常有限,目前对岩石图像分类的进一步研究还存在一定困难,在未来的研究中,我们将致力于把长石砂岩颜色、胶结情况、孔渗特征等作为分类特征列入分类方案,并尝试将各种分类方案在其他岩性上进行推广。

参考文献

- [1] Singh N, Singh T, Tiwary A, *et al.* Textural identification of basaltic rock mass using image processing and neural network[J]. **Computers & Geosciences**, 2010, 14(2): 301-310.
- [2] Mlynarczuk M, Górszczyk A, s'ipek B. The application of pattern recognition in the automatic classification of microscopical images[J]. **Computers & Geosciences**, 2013, 60(10): 126-133.
- [3] 郭超, 刘 焯. 多色彩空间下的岩石图像识别研究[J]. **科学技术与工程**, 2014, 14(18): 247-251+255.
Guo Chao, Liu Ye. Research on rock image recognition in multi-color space[J]. **Science Technology and Engineering**, 2014, 14(18): 247-251+255.
- [4] 程国建, 殷娟娟. 基于 SVM 的岩石薄片图像分类[J]. **科技创新与应用**, 2015, (1): 38.
Cheng Guojian, Yin Juanjuan. SVM-based rock slice image classification[J]. **Science and Technology Innovation and Application**, 2015, (1): 38.
- [5] 白 林, 魏 昕, 刘 禹, 等. 基于 VGG 模型的岩石薄片图像识别[J]. **地质通报**, 2019, 38(12): 2 053-2 058.
Bai Lin, Wei Xin, Liu Yu, *et al.* Rock thin slice image recognition based on VGG model[J]. **Geological Bulletin**, 2019, 38(12): 2 053-2 058.
- [6] 程国建, 杨 静, 黄全舟, 等. 基于概率神经网络的岩石薄片图像分类识别研究[J]. **科学技术与工程**, 2013, 13(31): 9 231-9 235.
Cheng Guojian, Yang Jing, Huang Quanzhou, *et al.* Study on classification and recognition of rock slice image based on probabilistic neural network[J]. **Science Technology and Engineering**, 2013, 13(31): 9 231-9 235.
- [7] 程国建, 郭文惠, 范鹏召. 基于卷积神经网络的岩石图像分类[J]. **西安石油大学学报(自然科学版)**, 2017, 32(4): 116-122.
Cheng Guojian, Guo Wenhui, Fan Pengzhao. Rock image classification based on convolutional neural network[J]. **Journal of Xi'an Shiyou University(Natural Science Edition)**, 2017, 32(4): 116-122.
- [8] 张 野, 李明超, 韩 帅. 基于岩石图像深度学习的岩性自动识别与分类方法[J]. **岩石学报**, 2018, 34(2): 333-342.
Zhang Ye, Li Mingchao, Han Shuai. Automatic lithology recognition and classification method based on deep learning of rock image[J]. **Acta Petrologica Sinica**, 2018, 34(2): 333-342.
- [9] 程国建, 范鹏召. 基于深度信念网络的岩石粒度分类[J]. **西安石油大学学报(自然科学版)**, 2018, 33(3): 107-112.
Cheng Guojian, Fan Pengzhao. Rock size classification based on deep belief network[J]. **Journal of Xi'an Shiyou University(Natural Science Edition)**, 2018, 33(3): 107-112.
- [10] 程国建, 张福临. 基于 SinGAN 的岩石薄片图像超分辨率重建[J]. **西安石油大学学报(自然科学版)**, 2021, 36(2): 116-121.
Cheng Guojian, Zhang Fulin. Super-resolution reconstruction of rock slice image based on SinGAN[J]. **Journal of Xi'an Shiyou University(Natural Science Edition)**, 2021, 36(2): 116-121.
- [11] 李坤伦, 魏泽发, 宋焕生. 基于 SqueezeNet 卷积神经网络的车辆颜色识别[J]. **长安大学学报(自然科学版)**, 2020, 40(4): 109-116.
Li Kunlun, Wei Zefa, Song Huansheng. Vehicle color recognition based on SqueezeNet convolutional neural network[J]. **Journal of Chang'an University(Natural Science Edition)**, 2020, 40(4): 109-116.
- [12] 霍爱清, 张文乐, 李浩平. 基于深度残差网络和 GRU 的 SqueezeNet 模型的交通路标识别[J]. **计算机工程与科学**, 2020, 42(11): 2 030-2 036.
Huo Aiqing, Zhang Wenle, Li Haoping. Traffic road sign recognition based on deep residual network and GRU's SqueezeNet model[J]. **Computer Engineering and Science**, 2020, 42(11): 2 030-2 036.
- [13] 鲁元平, 罗志聪. 基于 Squeezenet 模型的蛇类图像识别[J]. **电脑知识与技术**, 2021, 17(7): 12-14.
Lu Yuanping, Luo Zhicong. Snake image recognition based on Squeezenet model[J]. **Computer Knowledge and Technology**, 2021, 17(7): 12-14.
- [14] Iandola F N, Han S, Moskewicz M W, *et al.* Squeezenet: Alexnet-level accuracy with 50x fewer parameters and < 0.5 mb model size[J]. **arXiv preprint arXiv**:1602.07360, 2016.
- [15] 高 婷, 杨 洋, 何 江. 人工智能在岩石图像上的应用综述[J]. **中国石油和化工标准与质量**, 2020, 40(20): 98-100.
Gao Ting, Yang Yang, He Jiang. Summary of the application of artificial intelligence in rock image[J]. **China Petroleum and Chemical Standards and Quality**, 2020, 40(20): 98-100.
- [16] 何 杰, 王 华, Eduardo Garzanti. 砂岩(砂)的岩 v 相分析和分类标准[J]. **地球科学**, 2020, 45(6): 2 186-2 198.
He Jie, Wang Hua, Eduardo Garzanti. Sandstone (sand) lithofacies analysis and classification standards[J]. **Earth Science**,

2020,45(6):2186-2198.

- [17] 董亮,段正泰,龚彬. 基于卷积神经网络和迁移学习的图像分类[J]. 信息与电脑(理论版),2021,33(3):77-78.
Dong Liang,Duan Zhengtai,Gong Bin. Image Classification Based on Convolutional Neural Network and Transfer Learning[J]. **Information and Computer(Theoretical Edition)**,2021,33(3):77-78.
- [18] Yaqiong Yao,HaiYing Wang. Optimal subsampling for softmax regression[J]. **Statistical Papers**,2019,60(2).
- [19] Hailong Xi,Haiyan Liu,Yu Zhang. Recognition and Optimization Algorithm of MNIST Dataset Based on LeNet5 Network Structure[A]. Wuhan Zhicheng Times Cultural Development Co.,Ltd. Proceedings of the 2018 International Conference on Transportation & Logistics,Information & Communication,Smart City(TLICSC 2018)[C]. Wuhan Zhicheng Times Cultural Development Co.,Ltd:武汉志诚时代文化发展有限公司,2018:7.
- [20] 郭敏钢,宫鹤. AlexNet改进及优化方法的研究[J]. 计算机工程与应用,2020,56(20):124-131.
Guo Mingang,Gong He. Research on the improvement and optimization method of AlexNet[J]. **Computer Engineering and Applications**,2020,56(20):124-131.
- [21] 吴军,邱阳,卢忠亮. 基于改进的SqueezeNet的人脸识别[J]. 科学技术与工程,2019,19(11):218-223.
Wu Jun,Qiu Yang,Lu Zhongliang. Face recognition based on improved SqueezeNet[J]. **Science Technology and Engineering**,2019,19(11):218-223.
- [22] 魏泽发,崔华. 基于SqueezeNet卷积神经网络的车辆检测[J]. 物联网学报,2020,4(3):120-125.
Wei Zefa,Cui Hua. Vehicle detection based on SqueezeNet convolutional neural network[J]. **Journal of the Internet of Things**,2020,4(3):120-125.

RESEARCH ON CLASSIFICATION OF ROCK SECTION IMAGE BASED ON SQUEEZENET CONVOLUTIONAL NEURAL NETWORK

Cheng Guojian¹, Li Bi¹, Wan Xiaolong², Yao Weihua², Wei Xinshan²

1. School of Computer Science, Xi'an Shiyou University, Xi'an, Shanxi 710065, China;
2. Research Institute of Exploration & Development, Changqing Oil field Company, PetroChina, Xi'an, Shanxi 710018, China

Abstract: In this paper, lightweight convolution neural network structure SqueezeNet is applied to rock slice image classification in order to solve the previous problems of low portability and slow classification speed in geological research. The experimental data set is 10026 feldspar sandstone images (image size is 224×224 pixels) from an oilfield area of Ordos Basin. Through training of SqueezeNet network model, the classification of rock section images is realized in a short time, and a good classification is achieved, whose classification accuracy of verification set is up to 90.88%. Experimental results show that the proposed model ensures the accuracy, greatly reduces the model parameters, and makes the model size only 4.78 MB. Therefore, the newly proposed technique improves the speed of rock classification and enhances the portability of the model.

Keywords: rock section images; convolutional neural network; SqueezeNet

ISSN 1001-6872(2021)04-0094-09; CODEN:KUYAE2

Synopsis of the first author: Cheng Guojian, male, 57 years old, professor, Artificial intelligent and applications. Now he is engaged in the Artificial intelligent, machine learning, pattern recognition etc.